LFC (Linguaggi Formali e Compilatori) - Note del Corso

Edoardo Lenzi

November 9, 2017

Contents

Chapter 1

Introduzione

Un compilatore é un programma che legge un **linguaggio source** e lo traduce in un `equilvalente` **linguaggio di programmazione target**. Solitamente il compilatore compila in `assembly` e poi un **assembler** produce codice macchina. Se il target language e un programma eseguibile puó processare input e produrre output.

Un **interprete** é un altro tipo di language processor, invece di tradurre il linguaggio lo esegue direttamente quindi piglia sia il source program che gli input e processa l'output

Infine il **preprocessore** risolve le macro nel sorgente codificandole in linguaggio nativo (espandendole) prima di compilare.

> Solitamente il compilato va piú veloce mentre l'interprete ti da diagnosi piu accurate dato che esegue il codice. Nel caso di Java compilo il sorgente in linguaggio intermedio `bytecode` che poi interpreto sulla JVM.

Il **linker** "linka" assieme moduli e librerie dove ho riferimenti ad altri file (risolve gli indirizzi). Il **loader** invece fa il merge in memoria per l'esecuzione.

1.1 Front-End of the Compiler

La **parte analitica** del processo di compilazione spacca la sorgente in parti costituenti e impone su di esse una struttura grammaticale (stile dtd); sfrutta questa struttura per creare una rappresentazione intermedia. Se non passa la validazione grammaticale mi tira errori. Il sorgente viene storicizzato in una struttura dati chiamata **symbol table**.

1.2 Back-End of the Compiler

La **parte di sintesi** invece traduce il sorgente guardando la rappresentazione intermedia e la symbol table; le parti di analisi e sintesi sono chiamate anche **front-end of the copiler** mentre le restanti **back-end**.

1.3 Lexical analysis

Fa uno scan e raggruppa le parole in **lexems**, per ogni lexem genera un **token** della forma

```
(token name, attribute value)
```

Il `token name` é un simbolo astratto usato nella syntax analysis mentre il `value` é un puntatore alla symbol table entry.

ie)

`position = initial + rate * 60` diventa `(id, 1) (=) (id, 2) (+) (id, 3) (*) (60)` gli operatori matematici sono simboli astratti che non hanno attribute value (?non sono referenziati nella symbol table?).

1.4 Session syntax analyzer

É un parsing, con i token crea una **rappresentazione ad albero (syntax tree)** nel quale il nodo é un operatore e i figli gli operandi.

gli operatori devono avere prioritá per costruire l'albero, la struttura grammaticale serve anche a definire le prioritá degli operatori.

1.5 Semantic analyzer

Piglia il `syntax tree` e guarda se é semanticamente consistente con la definizione del linguaggio. (ie `type checking`). Il linguaggio puo ammettere cast impliciti chiamati **coercizioni** o tirare cogne.

"*intofloat*"é una coercizione dell'intero 60 in float dato che gli altri operandi sono float.

1.6 Intermediate code generation

Nel processo di compilazione posso avere varie rappresentazioni intermedie come alberi etc.. Dopo semantic analysis solitmente creo una codice basso livello, machine-like, *"easy to produce and esay to translate int target machine code"*. Nella figura ho un tree address code ricavato dal syntax tree.

In un tree address code a destra ho al massimo un operatore (assembly like), e le operazioni sono in ordine.

Devo avere variabiline intermedie

1.7 Code generation

Segue la fase opzionale di **code optimization**, prende la rappresentazione inermedia e la mappa in un target language. Le istruzioni intermedie vengono tradote in istruzioni macchina (presumibilmente). Devo capire come mappare variabili su registri

Nella symbol table devo storicizzare tutti gli attributi di un variable name.

Solitamente posso agglomerare le fasi di analisi in front end pass e le altre in back end pass.

Chapter 2

Lezione 1

Vecchio sito

Riguardo linguaggi di analisi lessicale, si usano **simboli e caratteri**. Ho una tavola dei simboli creata in base al programma (e al compilatore). Restituisce un **token** (puntatore) ad un record nella tavola dei simboli. La maggior parte delle implementazioni usano un numero come **identificatore**. Analisi sintattica si basa sulla grammatica del linguaggio. Grammatica generativa vedere se é possibile generare una frase con la grammatica (syntax error). abstract syntax tree; nelle grammatiche formali metto in evidenza l'assegnamento.

$a = b + c \cdot 60$

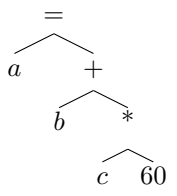

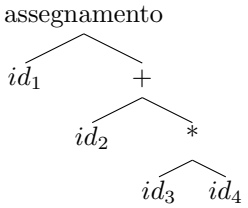

L'analisi semantica si occupa di vedere se c'é una corretta semantica (variabili dichiarate precedentemente). Se * necessita di un float allora 60 dev'essere convertito a float

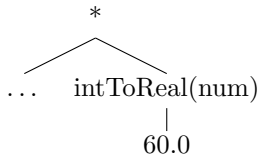

Generazione di codice intermedio:

$$\begin{array}{lll} temp_1 = & \text{intToReal}(60) & \\ temp_2 = & id_3 * temp1 & \text{VISITA DELL'ALBERO} \\ temp_3 = & id_2 + temp2 & \\ id_1 = & temp_3 & \end{array}$$

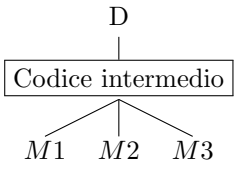

Una **grammatica** é una tupla G(V, T, S, P) con:

V	vocabolario
T	set simboli terminali
S	start symbol
P	set delle produzioni
V\T	simboli
ϵ	parola vuota, non puó essere un terminale!

Per convenzione i caratteri in maiuscolo denotano simboli non terminali mentre in minuscolo terminali. Quindi i simboli in T sono tutti lettere minuscole.

Considero X, Y variabili, generico simbolo in V e α β δ stringe su V^* (ripetere 0+ volte i simboli) $S \to aSb,\ S \to \epsilon,\ S \to A$, T=a, b non terminali $(V \backslash T)$ = S, A

Lo start symbol é usato nella prima produzione solo se produzioni libere dal contesto. Produzione legittima $aS \to b$ S a destra di una P non libera dal contesto.

Una grammatica generata é libera dal contesto (context free) se $\forall$ sua produzione ha la forma: $A \to \beta$ con A simbolo non terminale. ($\alpha \to \beta$, α deve contenere simboli non terminali).

$S \to ASb|\epsilon, \quad S \to \epsilon$ (privo di derivazione)

$S \to aSb \to ab$ $S \to aSb \to aaSbb \to aabb \implies \{a^n b^n \ / \ n \geq 0\}$ Struttura di bilanciamento per parentesi (blocchi begin end).

$\mu = \mu_1 \alpha \mu 2,\ \alpha \to \beta$ é produzione di grammatica G e γ é uguale a $\mu_1 \beta \mu_2$ derivazione in piú passi μ deriva in uno o piú passi data la grammatica G se ho una sequenza L(G) linguaggio generato da grammatica = insieme di stringhe

$S \to aSb,\ S \to aAb,\ S \to ab,\ A \to aaAb,\ A \to \epsilon\ \{w \ / \ w \in T^* \wedge s \implies {}^+W\}$ $\{a^n b^n | n > 0,\ S = 0,\ S = 1\}$ L = $\{a^n b^n \ / \ n > 0\}$

Dato il linguaggio L possono esistere piú grammatiche diverse tra loro che generano L é indecidibile il linguaggio generato dalla grammatica G, $\nexists algadatoGedatoaLchedicecheL = L(G)$.

$S \to aSBc|abc$ $cB \to Bc$ $bB \to bb$

$S \to AB$ $A \to A$ $A \to a$ $B \to Bb$ $B \to b$ tutto ció che deriva da A é indipendente da ció che deriva da B. aaa Ab b aaa aaAb bb a^5 aaAb b^3 $a^{2n+1} b^{n+1},\ n \geq 0$

$S \to aB$, $S \to \epsilon$, $L(G) = \emptyset$, $L(G) = \{\epsilon\}$, $S \to 0B|1A$, $A \to 0|0S|1AA$, $B \to 1|1S|0BB$

Definisco G_1 / il linguagigo L generato da G_1 = insieme delle parole $L(G) = \{a^k b^N, k > 0\}$ $S \to ab|aS|Sb$ $S \to aS|aB$ $B \to bB|b$, $S \to^+ a^i S$

$S \to AB,\ A \to Aa|a,\ B \to bB|b$

$L(G) = \{a^i b^m c^{2n}\}$

$S \to AB,\ A \to Aa|a,\ B \to bBcc|bcc$

$a^k b^n d^2 k,\ S \to Sdd|aBdd,\ B \to bB|b,\ S \to aSdd|abdd$

non terminale $\alpha \to \beta$ stringa grammatiche dipendenti dal contesto per vedere la differenza fra context dependent e quelle libere. Grammatiche libere si prestano in modo naturale a descrivere derivazioni in viste ad albero.

$S \to aSb|ab$ abstract syntax tree da albero di derivazione

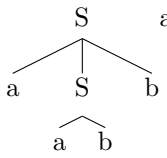

aabb, derivazione canonica $\mu \to \gamma$ Ambiguitá di G Nel caso di grammatiche libere si definiscono derivazioni canoniche destre e sinistre (rightmost/leftmost derivating) nel caso di rightmost si richiede che ad ogni passo di derivazione ($\mu \to \gamma$) venga rimpiazzato il terminale t a destra in μ (rispettivamente leftmost ρ a sinistra).

G é ambigua se $\exists\ L(G)$ / esistono per w due derivazioni canoniche distinte entrambe destre o entrambe sinistre. $E \to E + E|E * E|+$ (il + associa a sinistra)

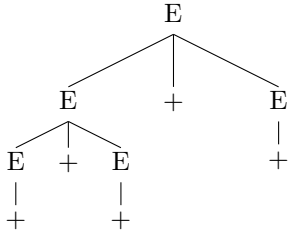

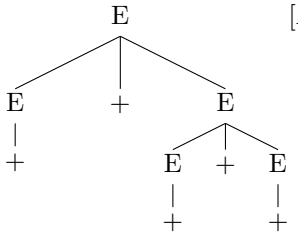

[Analogo con il *]

$S \to if\ b\ then\ S \mid if\ b\ then\ S\ else\ S \mid altro\ if\ b\ then\ if\ b\ then\ altro\ else\ altro\ if\ b\ then\ S\ else\ S$

G(V, T, S, P) Un linguaggio L é libero (da contesto) se esiste una grammatica libera G tale che L = L(G). In generale dato un linguaggio generale L ed una grammatica G $\nexists$ un algoritmo per dimostrare che L = L(G)

Grammatiche libere chiusura (se faccio operazioni su stringhe restano grammatiche libere)

Lemma: La classe dei linguaggi liberi é chiusa rispetto all'unione. Il linguaggio che contiene tutte e sole le parole $W \in L_1 \cup L_2$ é esso stesso un linguaggio libero.

L_1 é libero $\implies \exists\ G_1 = (V_1, T_1, S_1, P_1)$ / $L_1 = L(G_1)$ [analogo per L_2]

avendo ridenominati i non-terminali di G_1 e G_2 in modo da non avere anonimia

Lemma: La classe dei linguaggi liberi é chiusa rispetto alla concatenazione (se $L_1,\ L_2$ sono liberi allora $\{v_1 v_2 \ / \ v_1 \in L_1 \wedge v_2 \in L_2\}$ é un linguaggio libero).

G=(V,T,S,P) $\alpha \to \beta$, $\alpha,\ \beta \in B^+$ con al meno un terminale In una grammatica libera A (*nonterminale*) $\to \beta$ Le grammatiche libere sono quelle in cui tutte le produzioni in P hanno tutte forma $A \to \beta$.

Un linguaggio é libero se $\exists$ una grammaica libera che lo generale

ie) linguaggio $\{a^n b^n \ / \ n > 0\}$ libero perché $\exists$ una grammatica libera che lo genera (G_1). G_1 $S \to aSb/ab$ G_1 libera G_2 $s \to aAb,\ A \to aaAb,\ A \to \epsilon$ G_2 non libera $\square$

$L = \{vw \ / \ w \in \{a,b\}^*\}$ Con il **pumping lemma** posso dimostrare se un linguaggio é libero o meno.

Pumping lemma: Sia L un linguaggio libero allora $\exists\ p \in \mathbb{N}^+ \ / \ \forall\ z \in L :\ |z| > p\ \exists\ uvwxy \ / \ z = uvwxy \wedge |vwx| \leq p \wedge |vx| > 0 \wedge \forall\ i \in \mathbb{N} uv^i wx^i y \in L.$

$\exists\ p \in \mathbb{N}^+$	esiste una costante $p > 0$
$\forall\ z \in L :\ \|z\| > p$	ogni parola con piú elementi di p
$\exists\ uvwxy \ / \ z = uvwxy$	esistono 5 sottostringhe che compongono
$\|vwx\| \leq p$	la lunghezza delle 3 stringhe centrali é n
$\|vx\| > 0$	la seconda e la quarta non sono mai ent
$\forall\ i \in \mathbb{N} uv^i wx^i y \in L$	se ripeto i volte (i puó essere 0) la 2 e la

G $S \to aSb|ab$ G $S \to A,\ A \to aAb|ab$

Chomsky normal form (no doppioni)

ie) G_1 $S \to aSb|ab|B,\ B \to aBb|ab \leftarrow$ doppioni G $S \to A,\ A \to aAb|ab$

Dim L é linguaggio libero $\implies$ $\exists$ una grammatica G in Chomsky Normal Form tale che L = L(G). Definisco P come la lunghezza della parola piú lunga che puó essere derivata usando un albero di derivazione i cui cammini dalla radice sono lunghi al piú come il numero di simboli non teminali della grammatica ($|V \backslash T|$).

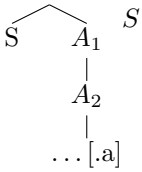

$S \to aSb|ab$ Albero di derivazione: piglio un non terminale e lo espando con figli quanto vale β

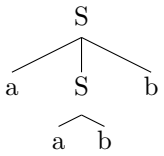

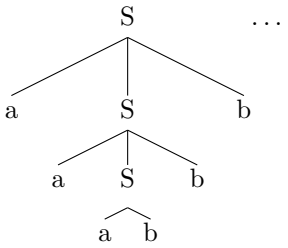

P é la lunghezza della parola piú lunga che posso linitare. $S \to A_1 \to A_2 \to ... \to A_k \to a$ [tutti simboli non terminali tranne a]

ie) p = 2, se prendo una qualunque perola piú lunga di 3 generata da G, aaaabbbb la posso dividere in 5 con due pumpable u=aa, v=a, w=abb, x=b, y=b

Se prendo $z \in L \wedge |z| > p \implies$ ho dovuto usare un albero di derivazione / $\exists$ al meno un cammino piú lungo di $|V \backslash T|$ per definizione di z. $\implies$ ho un non terminale ripetuto al meno due volte $\implies$ $\exists$ al meno un non terminale che occorre al nomo 2 volte lungo quel cammino

con l'un-pumping la parola sta sempre nel linguaggio (taglio un pezzo di albero) ie)

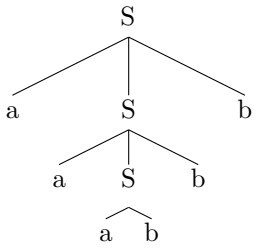

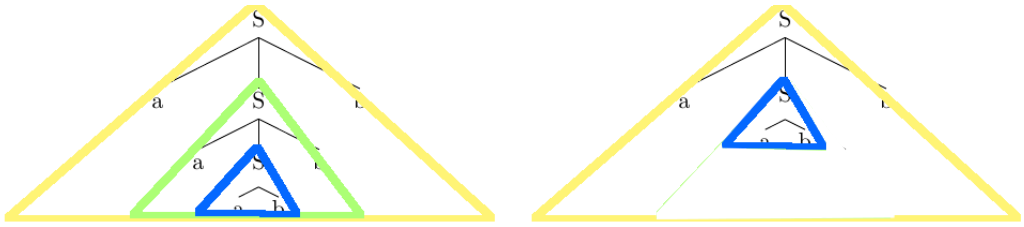

$\square$

Dato che w e x non possono essere entrambi nulli al massimo avró $A \to aA,\ o\ A \to Aa$

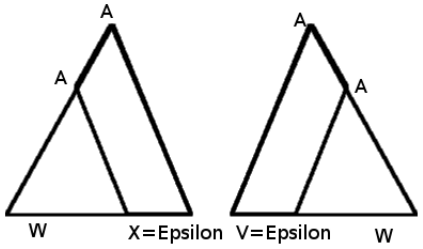

ie) linguaggio libero $\{a, b\},\ S \to ab$

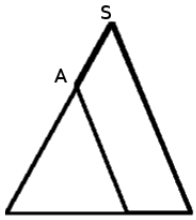

2.1 Uso del Pumping Lemma per determinare linguaggi liberi

Tesi: Sia L un linguaggio libero allora $\exists p \in \mathbb{N}^+ \ / \ \forall\ z \in L : |z| > p\ \exists\ uvwxy\ /\ (z = uvwxy \wedge |vwx| \leq p \wedge |vx| > 0 \wedge \forall\ i \in \mathbb{N} uv^i wx^i y \in L)$

Considero $L_1 = ww\ /\ w \in \{a, b\}^*$ non é libero

Dim: Suppongo L_1 libero, sia p un numero naturale positivo qualunque (se scelgo un p arbitrario la dim non serve a nulla). Sia $z = a^p b^p a^p b^p$ allora $z \in L_1,\ |x| > p$. Siano $uvwxy\ /\ z = uvwxy \wedge |vwx| \leq p \wedge |vx| > 0$, distinguiamo varie possibilitá:

1) vwx é composto da 'a ' che occorrono a sinistra (w_1)

2) vwx é a cavallo e contiene sia 'a ' che 'b ' in w_1

3) vwx contiene solo 'b ' in w_1

4) 'b ' in w_1 e 'a '$\in w_2$

5,6,7) ...speculare su w_2

Nei casi 1, 3, 5, 7 considero le parole $z^1 = uv^0wx^0y$ (i=0); nel caso 1 sono certo di togliere alcune occorrenze di a quindi avró $z^1 = a^k b^p a^p b^p,\ k < p \implies z^1 \notin L$. Nel caso 3 $z^1 = a^p b^k a^p b^p,\ k < p \implies z^1 \notin L$. Nel caso 5 $z^1 = a^p b^p a^k b^p,\ k < p \implies z^1 \notin L$. Nel caso 7 $z^1 = a^p b^p a^p b^k,\ k < p \implies z^1 \notin L$.

Nei casi 2, 4, 6 invece avró ancora $z^1 = uv^0wx^0y$ (i=0); Nel caso 2 $z^1 = a^k b^p a^p b^p,\ o\ a^p b^k a^p b^p,\ o\ a^j b^k a^p b^p,\ j, k < p \implies z^1 \notin L\ .\ ...$