Corso di Laurea Magistrale in Ingegneria Informatica
A.A. 2013-2014

Linguaggi Formali e Compilatori

Introduzione

Giacomo PISCITELLI

Scheduling

Orario delle lezioni

Martedi	ore	15:30 - 18.30	aula	4
Giovedi	ore	11:30 - 13.30	aula	14

Chiarimenti e informazioni

Orario ricevimento

Giovedi	ore	10.00 – 11.30

Per appuntamento

e-mail: piscitel@poliba.it

Obiettivi

- ***Cos'è un linguaggio di programmazione.***
- ***Come sono definiti i linguaggi di programmazione e come si definiscono i programmi.***
- ***Come questi linguaggi sono "implementati"***, ovvero come vengono eseguiti su una macchina (tipicamente, un computer).
- ***Quali sono le tecniche di traduzione*** per i moderni linguaggi di programmazione sia di tipo general purpose che per applicazioni specifiche.

Requisiti preliminari

- ✓ Conoscenza dei linguaggi di programmazione
- ✓ Conoscenza dei paradigmi di programmazione
- ✓ Conoscenza delle diverse modalità di allocazione della memoria
- ✓ Capacità di sviluppare applicazioni software anche complesse
- ✓ Conoscenza delle principali strutture dati e degli algoritmi per la loro gestione

Course Outline

Linguaggi di programmazione

Linguaggi e macchine astratte

Traduttori, compilatori e interpreti

Alfabeto, stringhe, vocabolario

Linguaggio, approcci alla definizione

Grammatiche e classificazione

Grammatiche regolari e context-free

Backus-Naur Form (BNF)

Automi

Struttura di un compilatore

Analisi lessicale (scanning)

Implementazione di scanner

Analisi sintattica (parsing)

Top-Down Parsing, LL Parsing

Bottom-Up Parsing, LR Parsing

Implementazione di parser

Analisi Semantica

Syntax-Directed Translation

Rappresentazione intermedia

Generazione del codice

Tecniche di ottimizzazione del codice

Il tema d'anno: obiettivo e contenuto

Modalità di esame

elaborato

gruppi di 2 – 3 persone

esame orale

discussione del progetto
contenuti teorici del corso

Materiale didattico

Testi

A.H. Aho, M.S. Lam, R. Sethi, J.D. Ullman,
"Compilers: principles, techniques & tools", second edition
"Compilatori: principi, tecniche e strumenti", seconda edizione,
Pearson/Addison-Wesley, 2007/2009.
*Il libro è spesso chiamato **Dragon Book** (il libro del dragone) a causa dell'immagine della copertina che, almeno nell'edizione originaria, raffigura il Cavaliere della Programmazione che lotta con il Dragone del design dei compilatori.*

J.E. Hopcroft, R. Motwani, J.D. Ullman
"Automi, Linguaggi e calcolabilità" vol. primo: Metodi sintattici
Addison-Wesley, 2003

Lucidi e materiale del docente

Altri testi

David Gries
"Principi di progettazione dei compilatori"
Collana di Informatica, Franco Angeli Editore

T.W. Pratt, M.V. Zelkowitz,
"Programming Languages: Design and Implementation",
Prentice Hall

Cos'è un Linguaggio di Programmazione (LdP)?

Una **qualsiasi notazione per descrivere algoritmi e strutture dati** può essere considerata un **linguaggio di programmazione**.

Le "frasi" di questi linguaggi sono programmi validi.

Per eseguire un programma, esso deve essere tradotto in una forma che può essere "compresa" da un calcolatore → **traduttore**

Per realizzare un traduttore si fa uso di principi e tecniche utili non solo per costruire compilatori, ma anche in molte altre aree dell'informatica.

Quanti sono i linguaggi di programmazione?

e cosa li distingue?

Risposta: più di **1500**

O almeno tanti sono i linguaggi che compaiono (alle ore 09.35 del 25/09/2013) all'URL:
http://www.99-bottles-of-beer.net/
(ma molti linguaggi non sono inclusi)

Non è pensabile conoscerli tutti!

È necessario qualche ***criterio per catalogare i diversi linguaggi***!

Sul sito 99-bottles-of-beer usano l'ordinamento alfabetico . . .

. . . ma, forse !?, ci sarà qualche criterio più "efficace".

Perché studiare i linguaggi di programmazione?

- per sfruttare al meglio i LdP conosciuti e migliorare la capacità di sviluppare algoritmi efficienti
- per ampliare il vocabolario dei costrutti disponibili
- per comprendere somiglianze e diversità fra i LdP
- per facilitare la scelta del LdP più adatto allo sviluppo di una particolare applicazione
- per facilitare l'apprendimento di nuovi LdP
- per facilitare il progetto di nuovi LdP

Linguaggi e Macchine

$$L \Leftrightarrow M_L$$

L: linguaggio di programmazione
M_L: macchina che ha L come linguaggio macchina

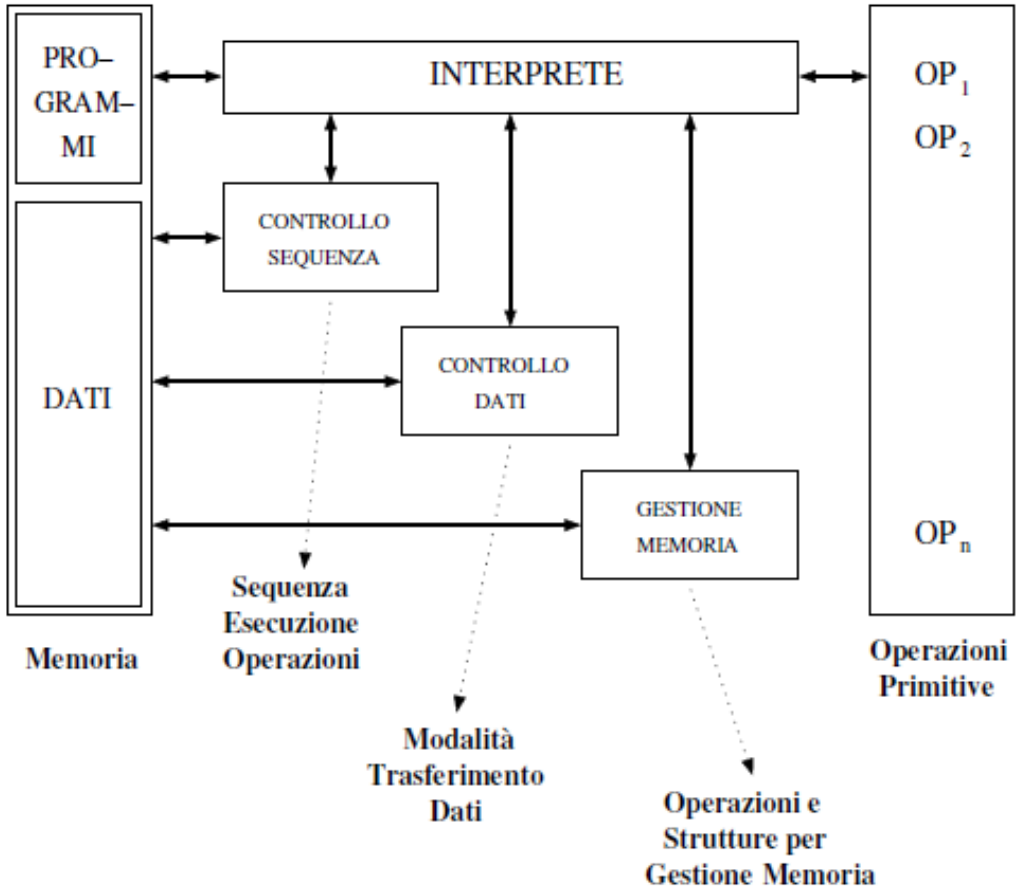

Il caso HARDWARE

Nel caso la Macchina sia la macchina HW convenzionale (o di von Neumann)

PROGRAMMI	$\rightarrow$	sequenze di istruzioni in linguaggio macchina HW
DATI	$\rightarrow$	registri, RAM (byte-parole), memoria di massa (settori)
OPERAZIONI MACCHINA	$\rightarrow$	operazioni aritmetico-logiche, lettura/scrittura RAM, . . .
CONTROLLO SEQUENZA	$\rightarrow$	strutture dati: program counter, operazioni di salto, . . .
GESTIONE MEMORIA	$\rightarrow$	stack, . . .
TRASFERIMENTO DATI	$\rightarrow$	modalità di indirizzamento, registro indice, . . .

Il caso HARDWARE

Il formato delle istruzioni

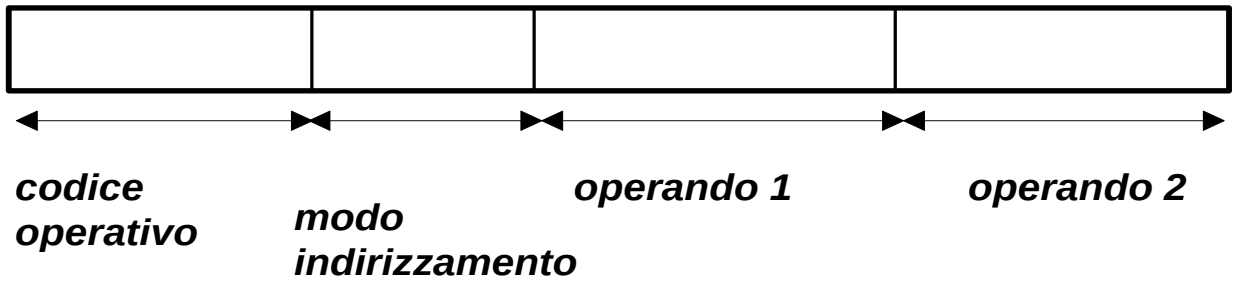

Il **codice operativo** è sempre presente ed identifica l'operazione da svolgere.

Il **modo di indirizzamento**, che indica come si fa riferimento ad un operando (*diretto*, *indiretto*, *relativo*, *immediato*).

Gli **operandi**, che possono anche mancare, specificano la dislocazione (in memoria centrale o in un registro generale della CPU) dei dati cui l'operazione si riferisce. Se un dato è in un registro, l'operando indica il numero di tale registro. Se un dato è in memoria, l'operando ne indica l'indirizzo.

Interprete

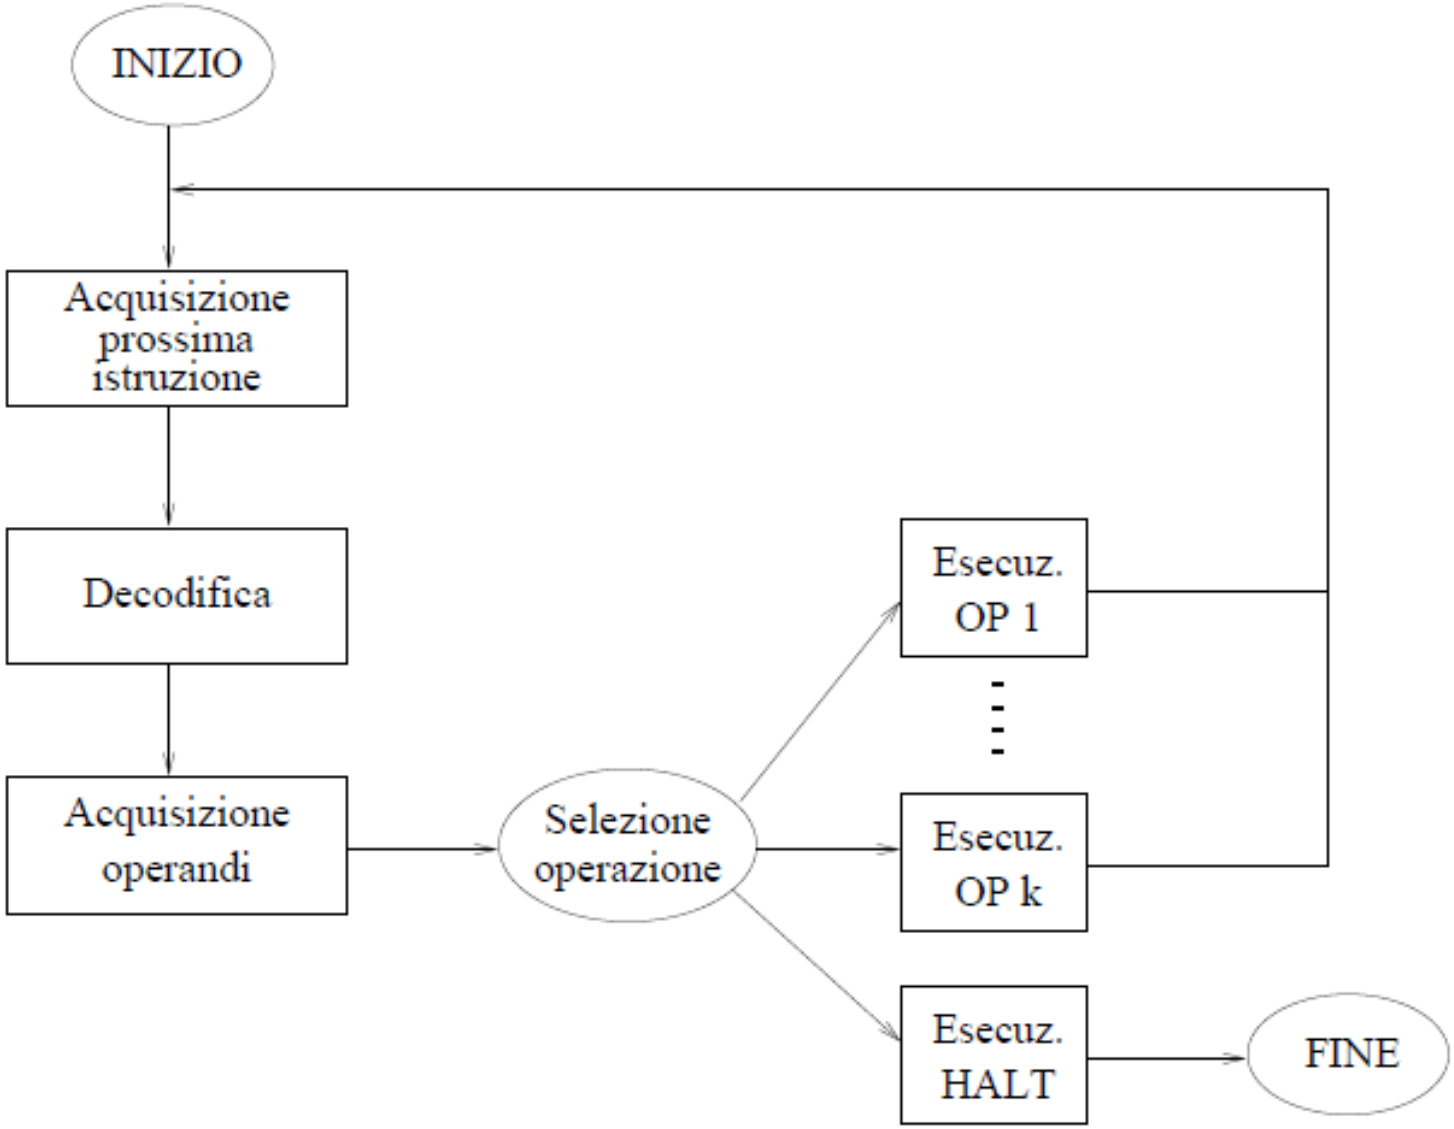
INIZIO
Acquisizione prossima istruzione
Decodifica
Acquisizione operandi
Selezione operazione
Esecuz. OP 1
Esecuz. OP k
Esecuz. HALT
FINE

Il linguaggio per la macchina di Von Neumann

Calcolare il valore dell'espressione:

$$z = (a+b)\cdot(c+d)$$

leggendo i valori delle variabili **a**, **b**, **c**, **d** dal dispositivo di ingresso e scrivendo il risultato **z** della valutazione sul dispositivo di uscita.

La istruzione binaria	La operazione svolta
0100000000010000	**Leggi** un valore dall'input e mettilo nella cella 16 (**a**)
0100000000010001	**Leggi** un valore dall'input e mettilo nella cella 17 (**b**)
0100000000010010	**Leggi** un valore dall'input e mettilo nella cella 18 (**c**)
0100000000010011	**Leggi** un valore dall'input e mettilo nella cella 19 (**d**)
0000000000010000	**Carica** il contenuto della cella 16 (**a**) nel registro A
0001000000010001	**Carica** il contenuto della cella 17 (**b**) nel registro B
0110000000000000	**Somma** i registri A e B
0010000000010100	**Scarica** il contenuto di A nella cella 20 (**z**) (ris.parziale)
0000000000010010	**Carica** il contenito della cella 18 (**c**) nel registro A
0001000000010011	**Carica** il contenito della cella 19 (**d**) nel registro B
0110000000000000	**Somma** i registri A e B
0001000000010011	**Carica** il contenuto della cella 20 (**z**) (ris. parziale) in B
1000000000000000	**Moltiplica** i registri A e B
0010000000010100	**Scarica** il contenuto di A nella cella 20 (**z**) (ris. totale)
0101000000010100	**Scrivi** il contenuto della cella 20 (**z**) (ris. totale) in output
1101000000000000	**Halt**

La memoria nella macchina di Von Neumann

Cella	0	0100000000010000
	1	0100000000010001
	2	0100000000010010
	3	0100000000010011
	4	0000000000010000
	5	0001000000010001
	6	0110000000000000
	7	0010000000010100
	8	0000000000010010
	9	0001000000010011
	10	0110000000000000
	11	0001000000010011
	12	1000000000000000
	13	0010000000010100
	14	0101000000010100
	15	1101000000000000
Spazio riservato per `a`	16	
Spazio riservato per `b`	17	
Spazio riservato per `c`	18	
Spazio riservato per `d`	19	
Spazio riservato per `z`	20	

Linguaggi e Macchine Astratte

Ogni linguaggio induce una macchina astratta definita dall'implementazione del linguaggio:

$$L \Rightarrow M_L$$

L: linguaggio
M_L: macchina che ha L come linguaggio macchina

Ogni macchina astratta definisce un "linguaggio macchina":

$$M \rightarrow L_M$$

M: macchina
L_M: linguaggio interpretato da M (programmi in L_M $\Leftrightarrow$ dati primitivi di M)

Paradigmi di linguaggi

È possibile catalogate i linguaggi in vari paradigmi:

Linguaggi imperativi (o procedurali)
Esempi: Pascal, C, FORTRAN, Perl

Linguaggi applicativi (o funzionali)
Esempi: LISP, MetaLanguage (ML)

Linguaggi orientati agli oggetti
Esempi: C++, Java, Smalltalk, Python

Linguaggi basati su regole (o dichiarativi)
Esempi: Prolog, YACC, Make

Linguaggi per sistemi distribuiti
Esempi: Lotos, CSP, PICT

Cosa distingue i diversi paradigmi?

Caratteristiche di un LdP

Un linguaggio di programmazione è definito da:

- **lessico**: le parole chiave, i simboli e le regole per la costruzione dei nomi
- **sintassi**: la forma di un programma
- **semantica**: il significato di un programma
- **implementazione**: come funziona un programma
  - tramite **compilazione** (traduzione) in un altro linguaggio
  - tramite **interpretazione**

Gerarchia di Macchine

La macchina astratta di un LdP è normalmente composta da una gerarchia di macchine:

M4 **Macchina Virtuale sviluppata dal Programmatore**
Implementata dal modello di esecuzione sviluppato in codice C

M3 **Macchina Virtuale C**
Implementata da librerie di run-time

M2 **Macchina Virtuale del Sistema Operativo**
Implementata da programmi in linguaggio macchina eseguiti dal FW

M1 **Macchina Virtuale Firmware (FW)**
Implementata da microcodice eseguito dall'hardware

M0 **Macchina Virtuale Hardware (HW)**
Implementata da dispositivi fisici

Realizzazione delle Macchine Astratte

La realizzazione di una macchina virtuale può essere:

- **diretta** via hardware (HW)
- **emulata** via firmware (FW)
- emulata via software (SW)
- una opportuna **combinazione** di HW, FW e SW

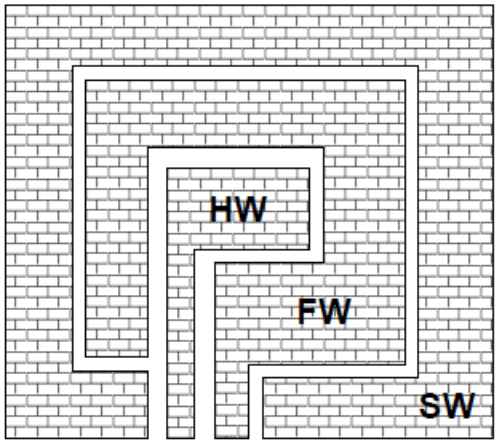

Implementazione di un LdP

L'implementazione del linguaggio *L* prevede:

1. La definizione di M_L
2. La "implementazione" di M_L
   - ✓ direttamente via HW
   - ✓ tramite emulazione di M_L su una macchina ospite M_O:
     - interpretazione
     - traduzione

Emulazione di M_L su M_O

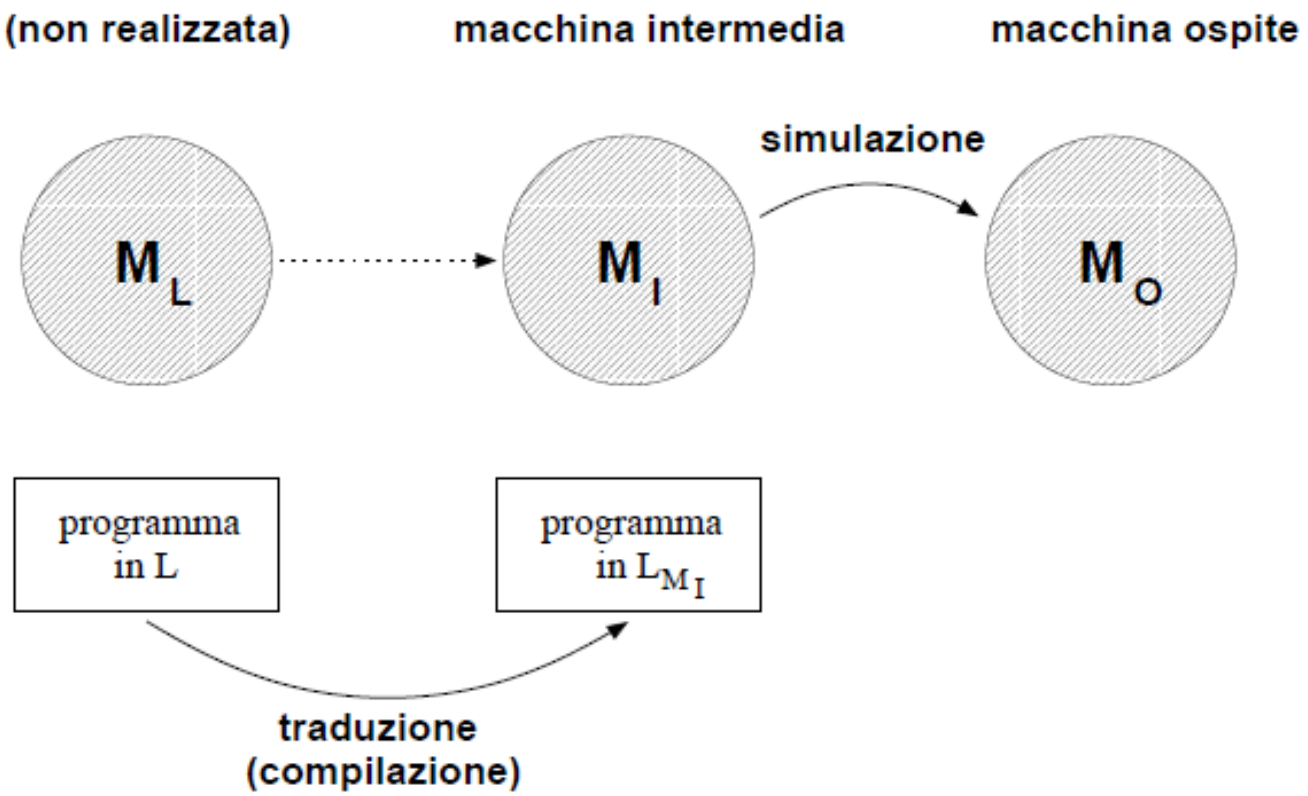

$M_L = M_I \Rightarrow$ implementazione puramente interpretativa

$M_I = M_O \Rightarrow$ implementazione puramente compilativa

Interpretazione e Compilazione

Per i linguaggi di alto livello non esistono implementazioni puramente interpretative o compilative: esse sono ottenute **combinando opportunamente traduzione e interpretazione**.

Nelle implementazioni **compilative** la parte di M_I differente da M_O è il cosiddetto **supporto a run time** (ad esempio in C il supporto per effettuare I/O).

Nelle implementazioni **interpretative** (anche le più spinte) c'è almeno una fase di traduzione di un programma in L in una rappresentazione interna.

Compilatori

I compilatori sono fondamentali nei moderni computer: essi agiscono come traduttori che consentono di trasformare un linguaggio di programmazione *human-oriented* in uno *computer-oriented.*

La maggior parte degli utenti vedono un compilatore come una "*black box*".

I compilatori consentono ai programmatori di ignorare i dettagli *machine-dependent* della programmazione.

Struttura di un compilatore

Se si considera in dettaglio l'operazione di traduzione compiuta da un compilatore, si osserva che essa avviene in due fasi fondamentali: **Analisi** e **Sintesi**.

Nella fase di **Analisi**, viene creata una rappresentazione intermedia del programma sorgente.

Nella fase di **Sintesi**, viene creato, partendo dalla rappresentazione intermedia, il programma target equivalente.

TOKEN, PATTERN, LESSEMA

What's a Token?

- A syntactic category
  - In English:
    noun, verb, adjective, …
  - In a programming language:
    Identifier, Integer, Keyword, Whitespace, …

- Un **lessema** è una sequenza di caratteri del *source program* che rispetta il pattern di un token.
- Un **token** o simbolo è un'astrazione indicante una classe di stringhe lessicali o lessemi. Ogni token ha un nome. Per esempio: **id**, **keyword**, **integer**, **real**, … esempio → il token di nome **id** indica la classe degli identificatori = { istanze di sequenze di caratteri che sono identificatori di costanti o variabili}.
- Un **pattern** è la descrizione della forma che possono assumere i lessemi di un token.

Le fasi di Analisi e Sintesi

Analisi

Partendo dal programma "sorgente", il compilatore individua in ogni istruzione gli elementi di base costituenti (**token**) e verifica che essi siano messi insieme rispettando la prevista struttura grammaticale dell'istruzione. Se ciò non è vero (la sintassi e/o la semantica non sono corrette) viene evidenziato un opportuno messaggio di errore, così da permettere che venga apportata la necessaria correzione.

Sono parti di questa fase l'Analizzatore lessicale (individua nel codice sorgente le sequenze significative di caratteri, detti lessemi, cioè insiemi di caratteri che hanno lo stesso significato (come identificatori, operatori, *keywords*, numeri, delimitatori, etc), raggruppati a loro volta in elementi lessicali detti token), l'Analizzatore Sintattico (usa i token individuati dall'analizzatore lessicale per ricostruire, sotto forma di albero sintattico, una descrizione di ogni singola istruzione capace di rappresentarne la struttura grammaticale), l'Analizzatore Semantico (controlla il "significato" delle istruzioni presenti nel codice in ingresso) e il Generatore di codice intermedio (traduce le frasi del programma dal linguaggio di alto livello in una rappresentazione intermedia).

Sintesi

Sono parti di questa fase il Generatore di Codice (il codice in rappresentazione intermedia è mappato nel codice della macchina target) e l'Ottimizzatore (il codice macchina viene analizzato e trasformato in codice equivalente ottimizzato per una specifica architettura).

Implementazione di un Compilatore

position = initial + rate * 60

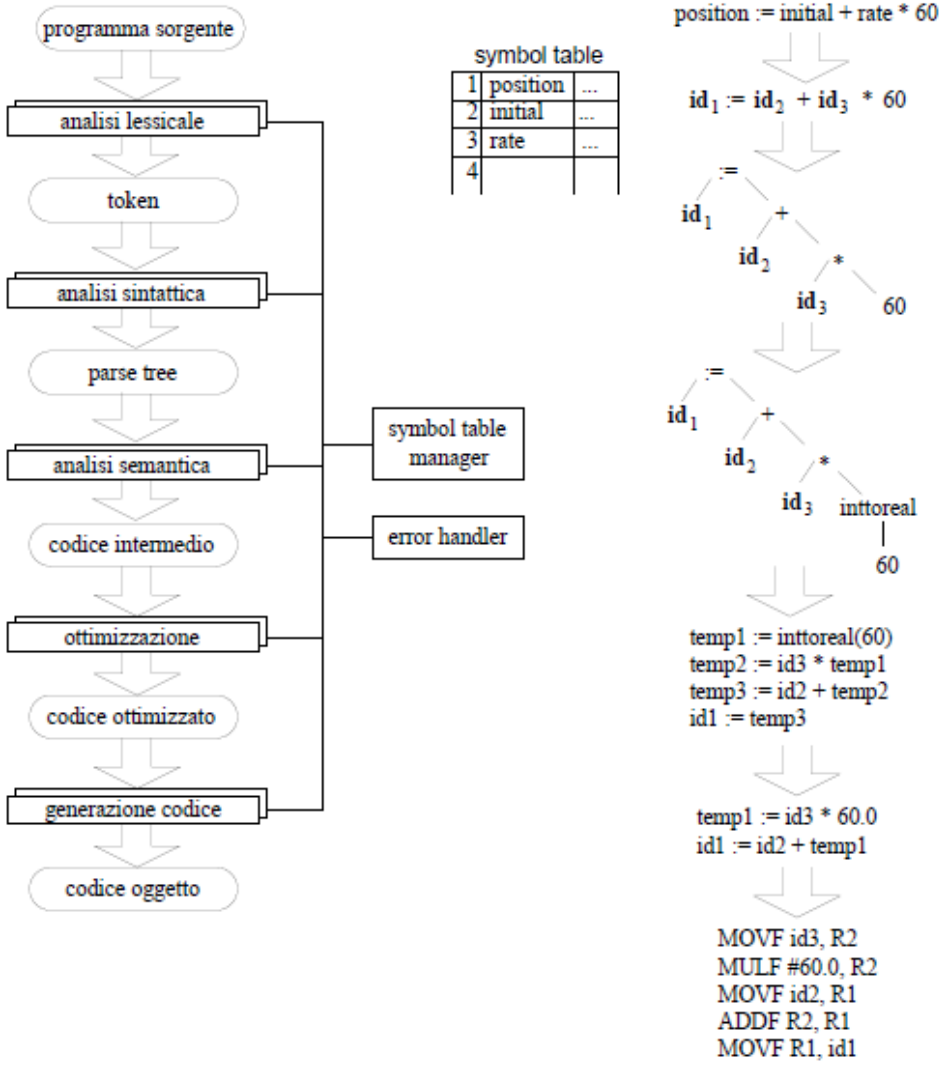

Ogni fase trasforma il programma sorgente da una rappresentazione in un altra

Nelle varie fasi si utilizzano: Gestore errori (Error handler) e Tabella simboli (Symbol table).

Compilatori a 2 passi: FRONT-END e BACK-END

I compilatori attuali dividono l'operazione di compilazione in due stadi principali: il **Front-end** e il **Back-end**.

Il Front-end dipende dal linguaggio sorgente, ma è indipendente dalla macchina target. Il compilatore traduce il sorgente in un linguaggio intermedio.

Il Back-end è indipendente dal linguaggio sorgente, ma dipende dalla macchina target. Nello stadio di Back-end avviene la generazione del codice oggetto e l'ottimizzazione.

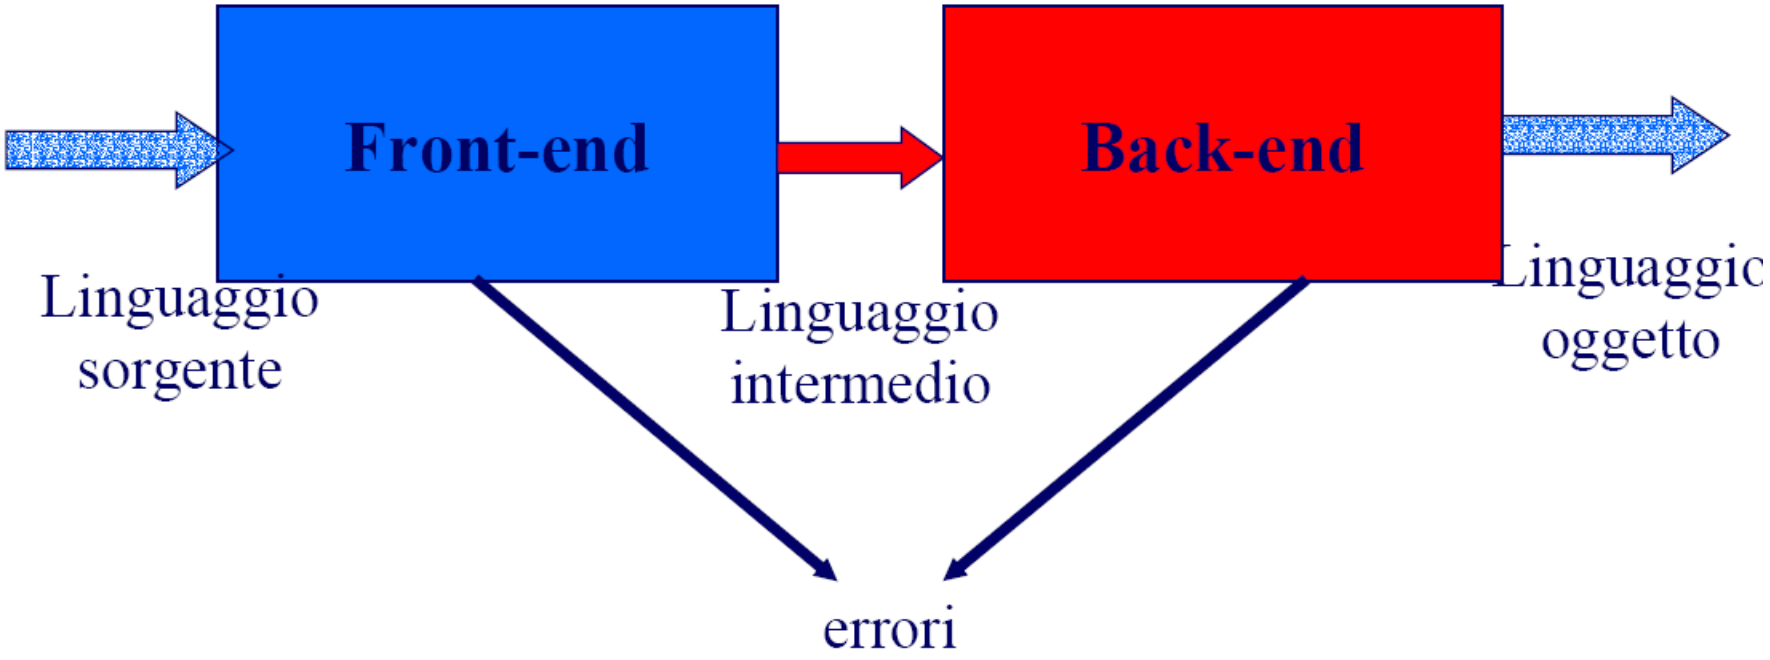

Front end e Back end si possono riutilizzare separatamente

Compilatori a due passi: il vantaggio del riutilizzo separato

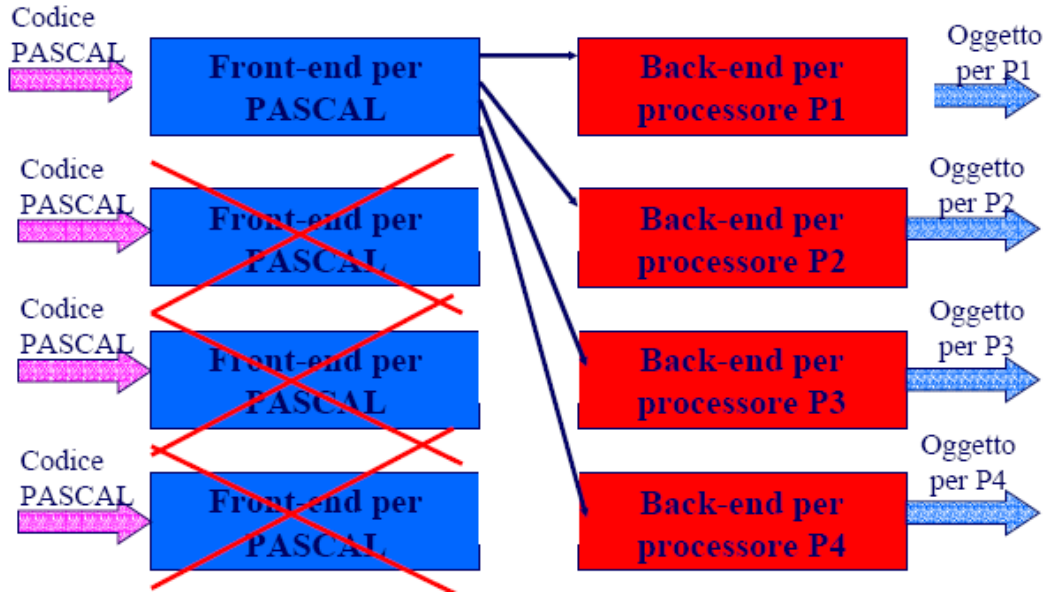

Retargeting

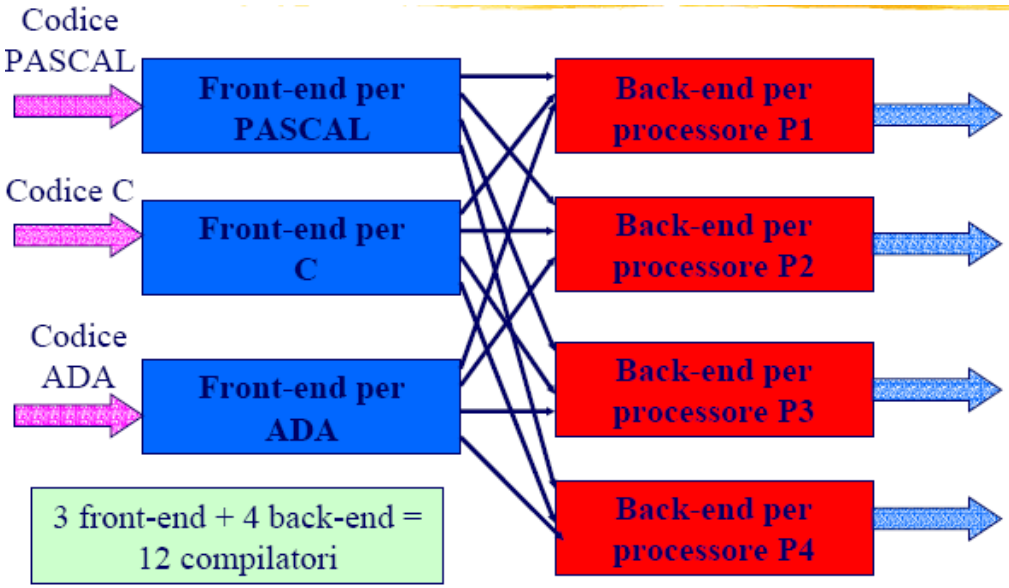

Multiple Front-end